

PROPOSAL TUGAS AKHIR



**EVALUASI KINERJA DAN INTERPRETABILITAS MODEL XGBOOST
TERKALIBRASI UNTUK PREDIKSI RISIKO DIABETES MENGGUNAKAN
EXPLAINABLE AI SHAP DAN LIME**

SEMINAR PROPOSAL

Diajukan sebagai salah satu syarat untuk melanjutkan tugas akhir/skripsi

**NAMA : NADIA RECILIA DAHMI
NIM : 20220801041**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS ESA UNGGUL**

2025

KATA PENGANTAR

Puji syukur saya panjatkan kehadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan petunjuk-Nya sehingga penulis dapat menyelesaikan tugas akhir dengan judul “Evaluasi Kinerja dan Interpretabilitas Model XGBoost Terkalibrasi untuk Prediksi Risiko Diabetes menggunakan Explainable AI SHAP dan LIME”.

Pada kesempatan kali ini penulis mengucapkan terima kasih juga kepada pihak-pihak yang terlibat dalam menyelesaikan tugas akhir ini:

1. Allah SWT Tuhan Yang Maha Esa karena telah memberikan kemudahan serta kesehatan sehingga penulis dapat menyelesaikan tugas akhir dengan tepat waktu.
2. Bapak Dr. Ir. Arief Kusuma A.P., ST., MBA., IPU, ASEAN Eng selaku Rektor Universitas Esa Unggul.
3. Bapak Dr. Gerry Firmansyah, S.T, M.Kom selaku Dekan Fakultas Ilmu Komputer Universitas Esa Unggul.
4. Ibu Diah Aryani, S.T, M.Kom selaku Wakil Dekan Fakultas Ilmu Komputer
5. Ibu Dr. Riya Widayanti, S.Kom, M.MSI selaku Kepala Program Studi Teknik Informatika Universitas Esa Unggul.
6. Bapak Muhamad Bahrul Ulum, S.Kom, M.Kom selaku Dosen Pembimbing Akademik.
7. Ibu Dr. Riya Widayanti, S.Kom, M.MSI selaku Dosen Pembimbing tugas akhir penulis yang telah memberikan waktu dan materi untuk membimbing penulis.
8. Kedua orang tua penulis yang telah mendukung, mendoakan, dan membantu penulis.
9. Seluruh staff administrasi Fakultas Ilmu Komputer yang telah membantu persuratan maupun materi.
10. Keluarga dan rekan-rekan yang senantiasa memberikan doa, dukungan, dan semangat dalam menyelesaikan kegiatan dan laporan ini.

Penulis sadar bahwa tugas akhir ini masih jauh dari kata sempurna, oleh karena itu penulis menerima kritik dan saran yang membangun untuk penulis.

Jakarta, 30 Oktober 2025

Mahasiswa/i

Nadia Recilia Dahmi

NIM :2022080141

ABSTRAK

Judul : Evaluasi Kinerja dan Interpretabilitas Model XGBoost Terkalibrasi untuk Prediksi Risiko Diabetes menggunakan Explainable AI SHAP dan LIME

Nama : Nadia Recilia Dahmi

Program Studi : Teknik Informatika

Diabetes Melitus merupakan penyakit kronis yang menjadi salah satu penyebab kematian utama di dunia. Upaya deteksi dini berbasis data menjadi krusial untuk mencegah komplikasi jangka panjang. Penelitian ini bertujuan untuk mengevaluasi kinerja dan interpretabilitas model *Extreme Gradient Boosting* (XGBoost) yang telah dikalibrasi menggunakan *Platt Scaling* dan *Isotonic Regression* untuk prediksi risiko diabetes. Model dievaluasi menggunakan *CDC Diabetes Health Indicators Dataset* yang terdiri dari lebih dari 70.692 observasi responden dewasa dengan distribusi seimbang antara penderita diabetes dan non-diabetes (masing-masing 50%). Selain itu, pendekatan *Explainable Artificial Intelligence* (XAI) diterapkan melalui metode SHAP (*SHapley Additive Explanations*) dan LIME (*Local Interpretable Model-Agnostic Explanations*) guna memberikan transparansi terhadap hasil prediksi. Evaluasi dilakukan berdasarkan metrik AUC-ROC, F1-Score, Brier Score, dan *calibration curve*. Hasil yang diharapkan adalah model prediksi risiko diabetes yang tidak hanya akurat (ditargetkan $AUC > 0.85$) tetapi juga memiliki probabilitas yang terkalibrasi ($Brier Score < 0.15$) dan dapat dijelaskan secara komprehensif. Selain itu, analisis SHAP dan LIME memberikan wawasan interpretatif terhadap kontribusi fitur-fitur klinis seperti tekanan darah tinggi, indeks massa tubuh (BMI), kolesterol tinggi, dan aktivitas fisik terhadap prediksi risiko diabetes. Temuan ini menegaskan bahwa kombinasi antara kalibrasi dan interpretabilitas dapat meningkatkan keandalan serta transparansi model AI di bidang medis.

Kata Kunci: Diabetes, XGBoost, Kalibrasi, SHAP, LIME, Explainable AI.

ABSTRACT

Title : Performance Evaluation and Interpretability of Calibrated XGBoost Model for Diabetes Risk Prediction using Explainable AI SHAP and LIME
Name : Nadia Recilia Dahmi
Study program : Informatics Engineering

Diabetes Mellitus is a chronic disease that is one of the leading causes of death worldwide. Data-driven early detection efforts are crucial to prevent long-term complications. This study aims to evaluate the performance and interpretability of the *Extreme Gradient Boosting* (XGBoost) model calibrated using Platt Scaling and Isotonic Regression for diabetes risk prediction. The model was evaluated using the CDC Diabetes Health Indicators Dataset consisting of more than 70,692 observations of adult respondents with a balanced distribution between diabetics and non-diabetics (50% of each). In addition, the Explainable Artificial Intelligence (XAI) approach was applied through the SHAP (SHapley Additive Explanations) and LIME (Local Interpretable Model-Agnostic Explanations) methods to provide transparency to the prediction results. The evaluation was carried out based on the AUC-ROC, F1-Score, Brier Score, and calibration curve metrics. The expected outcome is a diabetes risk prediction model that is not only accurate (targeted AUC > 0.85) but also has a calibrated probability (Brier Score < 0.15) and can be explained comprehensively. Furthermore, SHAP and LIME analyses provide interpretive insights into the contribution of clinical features such as high blood pressure, body mass index (BMI), high cholesterol, and physical activity to diabetes risk prediction. These findings confirm that the combination of calibration and interpretability can improve the reliability and transparency of AI models in the medical field.

Keywords: Diabetes, XGBoost, Calibration, SHAP, LIME, Explainable AI

DAFTAR ISI

KATA PENGANTAR	2
ABSTRAK	3
DAFTAR ISI	5
BAB I PENDAHULUAN.....	6
1.1 Latar Belakang.....	6
1.2 Identifikasi Masalah.....	6
1.3 Rumusan Masalah.....	7
1.4 Tujuan Penelitian.....	7
1.5 Manfaat Penelitian	7
1.6 Lingkup Penelitian	8
1.7 Kerangka Berpikir	9
1.8 Sistematika Penulisan Penelitian	9
BAB II TINJAUAN PUSTAKA	11
2.1 Prediksi Diabetes dengan Machine Learning	11
2.2 Kalibrasi Model Machine Learning	11
2.3 Explainable AI (XAI) dalam Kesehatan	12
2.3.1 SHAP (Shapley Additive Explanations)	12
2.3.2 LIME (Local Interpretable Model-Agnostic Explanations).....	12
2.4 Penelitian Terdahulu	12
BAB III METODOLOGI PENELITIAN	19
3.1 Desain Penelitian	19
3.2 Data dan Sumber Data	20
3.3 Alat dan Teknologi	21
BAB IV HASIL DAN PEMBAHASAN (<i>Bab ini akan diisi setelah penelitian selesai dilakukan</i>)	22
BAB V KESIMPULAN DAN SARAN (<i>Bab ini akan diisi setelah penelitian selesai dilakukan</i>)	23
5.1 Kesimpulan	23
5.1 Saran	23
DAFTAR PUSTAKA	24
LAMPIRAN.....	26

BAB I

PENDAHULUAN

1.1 Latar Belakang

Diabetes Melitus (DM) merupakan penyakit metabolism kronis yang ditandai dengan peningkatan kadar glukosa darah akibat gangguan pada sensitivitas insulin, disfungsi sekresi insulin, atau keduanya, dan kini telah muncul sebagai salah satu tantangan kesehatan global utama (*American Diabetes Association*, 2023). Deteksi dini menjadi kunci dalam strategi pencegahan dan penanganan yang efektif. Dalam beberapa tahun terakhir, model *machine learning* seperti *XGBoost* (*Extreme Gradient Boosting*) telah menunjukkan performa yang sangat baik dalam tugas klasifikasi medis, termasuk prediksi diabetes, berkat kemampuannya menangani hubungan non-linier yang kompleks antar fitur.

Algoritma *machine learning* seperti *Extreme Gradient Boosting* (XGBoost) memiliki kinerja yang sangat baik dalam tugas klasifikasi medis, termasuk prediksi diabetes. Kajian sistematis Sánchez et al. (2025) mengonfirmasi bahwa XGBoost secara konsisten menunjukkan performa unggul dibandingkan algoritma lain seperti *Random Forest* dan *Logistic Regression* pada berbagai dataset medis. Penelitian oleh Firmansyah dan Rahman (2023) juga menunjukkan bahwa XGBoost mampu mencapai akurasi hingga 76% dalam prediksi diabetes menggunakan sembilan indikator klinis utama, melampaui model Random Forest (74%). Temuan ini diperkuat oleh Hossain et al. (2023) yang melaporkan akurasi tinggi (97,88%) pada model *Random Forest* dalam mendeteksi kemungkinan diabetes tahap awal, menunjukkan potensi besar algoritma *ensemble* dalam pemodelan medis berbasis data.

Namun, dua tantangan utama menghambat penerapannya secara luas di dunia klinis. Pertama, probabilitas yang dihasilkan model sering kali tidak terkalibrasi, artinya estimasi risiko tidak mencerminkan probabilitas kejadian sebenarnya, sehingga dapat menyesatkan dalam pengambilan keputusan. Kedua, sifat *black box* dari model *ensemble* yang kompleks menyulitkan tenaga medis untuk memahami alasan di balik suatu prediksi, yang merupakan prasyarat untuk membangun kepercayaan dan memenuhi prinsip *accountability* dalam kecerdasan buatan untuk kesehatan.

1.2 Identifikasi Masalah

Berdasarkan yang telah dijelaskan, dapat diidentifikasi beberapa permasalahan utama yang menjadi dasar dilakukannya penelitian ini sebagai berikut:

1. Estimasi probabilitas dari model XGBoost untuk prediksi diabetes cenderung tidak terkalibrasi (*uncalibrated*), baik *overconfident* maupun *underconfident*.

2. Kurangnya transparansi dan interpretabilitas model XGBoost menghambat pemahaman oleh non-teknis seperti dokter dan pasien.
3. Evaluasi model yang ada seringkali hanya berfokus pada metrik diskriminasi (seperti Akurasi dan AUC) tanpa mempertimbangkan keandalan kalibrasi dan konsistensi penjelasan model.

1.3 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, dapat dirumuskan permasalahan utama dalam penelitian ini sebagai berikut:

1. Bagaimana pengaruh penerapan teknik kalibrasi (*Platt Scaling* dan *Isotonic Regression*) terhadap keandalan probabilitas yang dihasilkan model XGBoost untuk prediksi risiko diabetes?
2. Bagaimana efektivitas metode SHAP dan LIME dalam memberikan interpretasi global dan lokal terhadap model XGBoost yang telah dikalibrasi?
3. Bagaimana perbandingan kinerja model XGBoost sebelum dan setelah kalibrasi ditinjau dari metrik diskriminasi (AUC, F1-Score) dan kalibrasi (Brier Score, ECE)?

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengevaluasi dan membandingkan keandalan probabilitas model XGBoost sebelum dan setelah dikalibrasi menggunakan *Platt Scaling* dan *Isotonic Regression*.
2. Menganalisis dan membandingkan kemampuan SHAP dan LIME dalam menjelaskan prediksi model secara global dan lokal.
3. Menghasilkan model prediksi risiko diabetes yang tidak hanya akurat tetapi juga terkalibrasi dan dapat diinterpretasi.

1.5 Manfaat Penelitian

Penelitian ini diharapkan mampu memberikan manfaat baik dalam pengetahuan teoritisnya, praktik kerja, maupun akademis, sebagai berikut:

1. Manfaat Teoretis

Penelitian ini memberikan kontribusi pada pengembangan ilmu pengetahuan di bidang *Data Science* dan *Explainable Artificial Intelligence* (XAI), khususnya dalam integrasi antara algoritma XGBoost yang telah dikalibrasi dan teknik interpretasi SHAP dan LIME untuk prediksi risiko penyakit kronis. Penelitian ini memperkuat literatur tentang pentingnya interpretabilitas dan reliabilitas model prediktif dalam konteks klinis.

2. Manfaat Praktis

Secara praktis, penelitian ini menghasilkan model prediksi risiko diabetes yang tidak hanya akurat tetapi juga dapat dijelaskan secara klinis, sehingga dapat digunakan sebagai alat bantu pengambilan keputusan oleh tenaga kesehatan. Selain itu, hasil penelitian ini juga dapat menjadi panduan teknis bagi pengembang sistem dan peneliti lain yang ingin membangun model serupa dengan pendekatan XAI yang transparan dan terkalibrasi.

3. Manfaat Akademis

Penelitian ini memberikan manfaat bagi kalangan akademisi dan mahasiswa yang mempelajari bidang *Machine Learning* dan kecerdasan buatan, khususnya dalam konteks penerapan *Explainable AI* dan kalibrasi probabilitas di domain medis. Hasil penelitian ini dapat digunakan sebagai referensi akademik untuk pengembangan kurikulum, bahan ajar, maupun penelitian lanjutan yang berfokus pada penggabungan aspek interpretabilitas, keandalan probabilistik, dan penerapan etis kecerdasan buatan di sektor kesehatan.

1.6 Lingkup Penelitian

In-Scope:

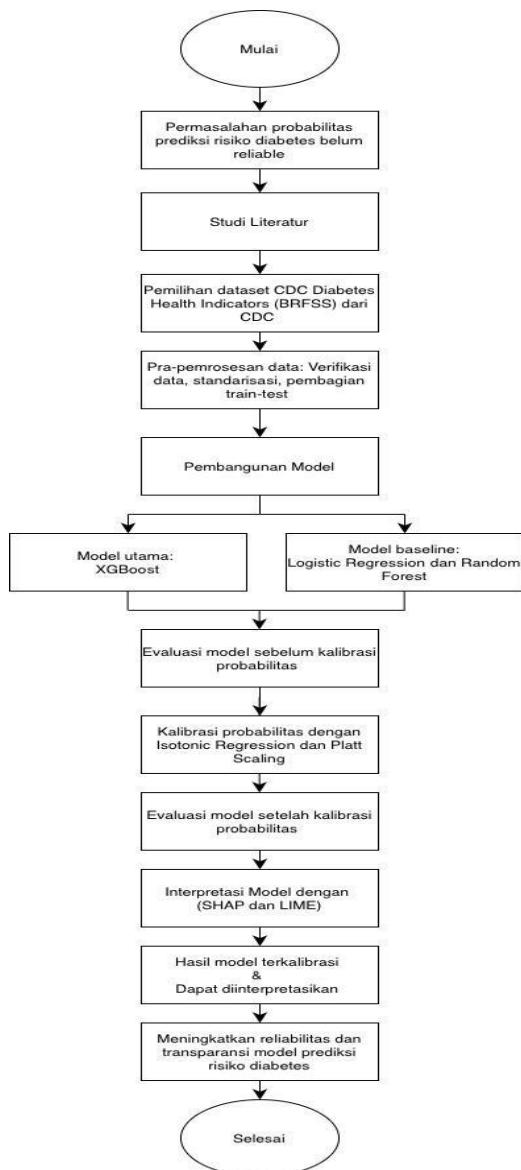
1. Pembangunan model prediksi risiko diabetes menggunakan algoritma XGBoost sebagai model utama.
2. Penggunaan *CDC Diabetes Health Indicators Dataset*, yaitu hasil survei *Behavioral Risk Factor Surveillance System* (BRFSS) tahun 2015 yang dikumpulkan oleh *Centers for Disease Control and Prevention* (CDC), Amerika Serikat, sebagai data survei kesehatan masyarakat yang telah dianonimkan.
3. Pra-pemrosesan data, yaitu pemeriksaan integritas data, normalisasi fitur numerik kontinu, dan pembagian dataset secara *stratified* menjadi *train-validation-test*.
4. Evaluasi kinerja model menggunakan metrik *AUC-ROC*, Akurasi, *Precision*, *Recall*, *Brier Score*.
5. Kalibrasi model dengan dua teknik, yaitu *Platt Scaling* dan *Isotonic Regression*, untuk dibandingkan dan menentukan metode terbaik.
6. Interpretasi hasil model menggunakan SHAP dan LIME untuk menganalisis kontribusi fitur secara global (keseluruhan model) dan lokal (setiap individu responden).

Out-of-Scope:

1. Integrasi langsung ke sistem *Electronic Health Record* (EHR) rumah sakit.
2. Penggunaan data pasien real-time atau non-anonim.
3. Pengembangan aplikasi atau *dashboard* produksi

1.7 Kerangka Berpikir

Kerangka berpikir penelitian ini dimulai dari permasalahan *black box* dan ketidakandalan probabilitas pada model prediktif di bidang medis. Solusi yang diusulkan adalah membangun sebuah *pipeline* yang terdiri dari: Pelatihan model XGBoost, Kalibrasi probabilitas *output* model, Interpretasi model menggunakan SHAP (untuk perspektif global) dan LIME (untuk perspektif lokal), dan Evaluasi komprehensif. *Output* dari *pipeline* ini adalah sebuah model yang telah terkalibrasi dan terinterpretasi, yang kemudian dianalisis untuk menjawab rumusan masalah. Analisis ini diharapkan dapat menghasilkan panduan dan rekomendasi yang bermanfaat bagi peneliti dan praktisi.



Gambar 1.1 Kerangka Berpikir

1.8 Sistematika Penulisan Penelitian

Sistematika penulisan yang membahas penelitian ini disusun ke dalam lima bab utama, sebagai berikut:

BAB I

PENDAHULUAN

Bab ini berisi latar belakang penelitian, identifikasi masalah, rumusan masalah, tujuan penelitian, manfaat penelitian, lingkup penelitian, kerangka berpikir, dan sistematika penulisan. Bab ini memberikan gambaran umum mengenai urgensi dan arah penelitian yang dilakukan.

BAB II

TINJAUAN PUSTAKA

Bab ini membahas landasan teori dan hasil penelitian terdahulu yang relevan dengan penelitian ini. Berisi pembahasan mengenai teori-teori dasar yang relevan seperti algoritma XGBoost, model pembanding seperti Logistic Regression dan Random Forest, konsep kalibrasi probabilitas, serta teknik Explainable AI (SHAP dan LIME). Selain itu, ditampilkan pula hasil-hasil penelitian terdahulu yang mendukung serta mengungkapkan kesenjangan penelitian yang menjadi dasar penelitian ini.

BAB III

Bab ini menjelaskan desain penelitian, sumber dan karakteristik data yang digunakan, tahapan pra-pemrosesan data, proses pembangunan model XGBoost serta model pembanding seperti Logistic Regression dan Random Forest, metode kalibrasi, teknik interpretasi menggunakan SHAP dan LIME, serta metrik evaluasi yang digunakan untuk menilai performa dan interpretabilitas model.

BAB IV

HASIL DAN PEMBAHASAN

Membahas hasil implementasi model prediksi diabetes berbasis XGBoost, hasil kalibrasi probabilitas, serta hasil interpretasi dari kedua metode XAI (SHAP dan LIME).

BAB V

KESIMPULAN DAN SARAN

Bab ini menyampaikan kesimpulan utama dari hasil penelitian, menjawab tujuan dan rumusan masalah, serta memberikan saran dan rekomendasi untuk pengembangan penelitian selanjutnya di bidang sistem pendukung keputusan klinis berbasis AI, serta integrasi hasil penelitian ke dalam praktik kesehatan masyarakat

BAB II

TINJAUAN PUSTAKA

2.1 Prediksi Diabetes dengan Machine Learning

Penelitian terkini menunjukkan bahwa algoritma *machine learning* (ML) terus berkembang untuk prediksi diabetes dengan akurasi yang semakin baik. Model berbasis *ensemble*, seperti Random Forest dan XGBoost, menonjol karena kemampuannya dalam menangkap hubungan non-linear antar variabel. Dalam studi oleh Kushan De Silva et al. (2020), model XGBoost mencapai akurasi 76% dan Random Forest 74% pada dataset dengan sembilan indikator (De Silva et al., 2020).

Model *machine learning* seperti XGBoost, Random Forest, dan SVM terbukti sebagai algoritma dengan performa terbaik untuk prediksi diabetes, sebagaimana ditunjukkan oleh tinjauan sistematis Khokhar et al. (2025). Studi empiris menunjukkan bahwa XGBoost sering unggul, misalnya pada penelitian Setiawan et al. (2023) dengan akurasi 92%, Zhang et al. (2020) dengan AUC 0,9182, serta Li et al. (2023) dengan AUC > 0,88. Random Forest juga konsisten menghasilkan akurasi >90% pada beberapa dataset (Santoso et al., 2024; Rahmawati et al., 2024). Model ensemble lanjutan seperti GA-XGBoost dan *stacking* (Chen et al., 2024) meningkatkan stabilitas prediksi. Namun, sebagian besar penelitian fokus pada akurasi dan belum mengevaluasi aspek kalibrasi probabilitas.

2.2 Kalibrasi Model Machine Learning

Kalibrasi model merupakan langkah penting untuk memastikan bahwa probabilitas yang diprediksi model sesuai dengan frekuensi empiris dari kejadian aktual. Artinya, jika model memprediksi risiko sebesar 0,7, maka sekitar 70% individu dengan prediksi tersebut benar-benar mengalami kondisi yang dimaksud. Van Calster et al. (2019) menegaskan bahwa kalibrasi yang baik merupakan syarat mutlak bagi model yang digunakan dalam pengambilan keputusan klinis. Sementara itu, Kull et al. (2020) menunjukkan bahwa proses kalibrasi tidak mengorbankan kemampuan diskriminasi model.

Beberapa pendekatan umum untuk kalibrasi model adalah *Platt Scaling* dan *Isotonic Regression*. *Platt Scaling* menggunakan regresi logistik terhadap output model dan efektif untuk hubungan monoton, sementara *Isotonic Regression* bersifat non-parametrik dan fleksibel untuk dataset besar. Feng et al. (2024) menunjukkan bahwa kombinasi *focal loss* dengan *gradient-boosted trees* mampu meningkatkan kalibrasi probabilitas secara signifikan tanpa menurunkan performa diskriminatif (Feng et al., 2024). Selain itu, Rosella et al. (2018) menekankan pentingnya *recalibration* model diabetes berdasarkan populasi berbeda. Demikian

pula, Kumar et al. (2024) menemukan bahwa model Eropa perlu dikalibrasi ulang untuk populasi India agar hasilnya valid (Kumar et al., 2024).

2.3 Explainable AI (XAI) dalam Kesehatan

Bidang *Explainable Artificial Intelligence* (XAI) berkembang pesat untuk menjawab tantangan interpretabilitas dari model *black box* seperti XGBoost. Dalam konteks medis, interpretabilitas menjadi krusial untuk meningkatkan kepercayaan klinis terhadap hasil model.

2.3.1 SHAP (Shapley Additive Explanations)

Berbasis teori permainan, SHAP memberikan nilai penting untuk setiap fitur secara global (untuk seluruh model) dan lokal (untuk satu prediksi tertentu). SHAP *summary plot* dan *force plot* adalah visualisasi yang umum digunakan. Zhang et al. (2023) mengeksplorasi pengaruh kalibrasi terhadap interpretasi model dan menemukan bahwa model yang terkalibrasi menghasilkan penjelasan SHAP yang lebih stabil dan konsisten. Mereka melaporkan peningkatan konsistensi sebesar 15% dalam *feature importance* setelah kalibrasi. SHAP memberikan hasil interpretasi paling stabil dibandingkan metode lain, terutama ketika model telah dikalibrasi (Zhou et al., 2025).

2.3.2 LIME (Local Interpretable Model-Agnostic Explanations)

LIME mengaproksimasi model kompleks dengan model yang lebih sederhana (seperti *linear model*) di sekitar sebuah instansi tertentu untuk menjelaskan alasan di balik prediksi individu tersebut. Integrasi LIME dengan XGBoost membantu menjelaskan fitur risiko diabetes secara lebih intuitif bagi tenaga medis (Sánchez et al., 2025). Studi terbaru oleh Lee & Park (2024) menginvestigasi hubungan antara kalibrasi probabilitas dan interpretabilitas lokal menggunakan LIME. Hasil penelitian mereka menunjukkan bahwa model yang terkalibrasi tidak hanya menghasilkan probabilitas yang lebih dapat diandalkan tetapi juga penjelasan lokal yang lebih *align* dengan pemahaman klinis.

2.4 Penelitian Terdahulu

Beberapa penelitian telah menggabungkan XGBoost dengan *Explainable AI* untuk prediksi diabetes, namun hanya sedikit yang secara eksplisit mengevaluasi dampak kalibrasi terhadap keandalan probabilitas dan konsistensi penjelasan yang dihasilkan oleh SHAP dan LIME. Kesenjangan inilah yang coba diisi oleh penelitian ini, dengan melakukan evaluasi komparatif yang holistik terhadap kinerja, kalibrasi, dan interpretabilitas.

No	Nama Peneliti (Tahun)	Judul	Metode	Hasil	Keterbatasan
1.	(Khokhar et	Advances in Systematic	Mengidentifikas	Tidak melakukan	

	al., 2025)	Artificial Intelligence for Diabetes Prediction: Insights from a Systematic Literature Review	Literature Review (ML models for diabetes)	i XGBoost, Random Forest, dan SVM sebagai model paling akurat untuk prediksi diabetes; menyoroti pentingnya interpretabilitas (SHAP/LIME).	eksperimen langsung; fokus pada tinjauan pustaka.
2.	Setiawan et al. (2023)	Implementasi Data Mining dalam Melakukan Prediksi Penyakit Diabetes Menggunakan Metode Random Forest dan XGBoost	Random Forest, XGBoost	Akurasi XGBoost mencapai 92%, lebih baik dibanding Random Forest.	Data uji terbatas pada wilayah tertentu; belum menggunakan metode interpretasi (SHAP/LIME).
3.	Kushan De Silva et al. (2020)	Use and Performance of Machine Learning Models for Type 2 Diabetes Prediction in Community Settings: A Systematic Review and	Systematic Review & Meta-Analysis	Model ML (khususnya ensemble) menunjukkan performa prediksi yang lebih baik dibanding regresi logistik tradisional.	Tidak membahas interpretabilitas model dan kalibrasi probabilitas.

		Meta-Analysis			
4.	Zhang et al. (2024)	Estimating Calibrated Risks Using Focal Loss and Gradient-Boosted Trees for Clinical Risk Prediction	Gradient Boosted Trees (XGBoost variant) dengan Focal Loss	Meningkatkan akurasi dan kalibrasi probabilitas prediksi medis.	Tidak fokus pada penyakit diabetes; bersifat umum untuk prediksi risiko klinis.
5.	Santoso et al. (2024)	Prediksi Kemungkinan Diabetes pada Tahap Awal Menggunakan Algoritma Klasifikasi Random Forest	Random Forest	Akurasi tinggi (91%) untuk prediksi dini diabetes berdasarkan parameter kesehatan dasar.	Tidak membandingkan dengan model lain; tanpa analisis interpretabilitas.
6.	Gogate, S., et al. (2024)	Transparent Diabetes Risk Prediction through Interpretable Machine Learning and XAI Integration	XGBoost, SHAP, dan LIME pada dataset PIMA Indians Diabetes	Model mencapai akurasi 86% dan AUC-ROC 93%; integrasi XAI meningkatkan transparansi model.	Tidak mengevaluasi kalibrasi probabilitas; hanya fokus pada interpretabilitas.
7.	Kumar, R., & Singh, M. (2024)	Machine Learning Interpretability in Diabetes Risk Assessment: A SHAP	XGBoost + SHAP; data 253.680 pasien	SHAP mengidentifikasi fitur utama: General Health, High BP, Age, BMI; meningkatkan	Tidak menilai reliabilitas probabilitas prediksi; hanya fokus pada interpretabilitas.

		Analysis		pemahaman klinis terhadap risiko diabetes.	
8.	Hasan, M., et al. (2023)	An Interpretable Framework for Predicting Type 2 Diabetes using ML and Explainable AI	XGBoost + LIME + SHAP; dua dataset klinis	Model mencapai akurasi 99,4% dan 92,59%; XAI efektif menjelaskan kontribusi fitur utama.	Tidak menguji kalibrasi probabilitas model; terbatas pada dua dataset.
9.	Wu, Q., et al. (2020)	An Explainable XGBoost–Based Approach Towards Assessing the Risk of Cardiovascular Disease in Patients with Type 2 Diabetes Mellitus	XGBoost + SHAP; data 560 pasien T2DM selama 5 tahun	Model menghasilkan AUC 71,13%; SHAP membantu menjelaskan pengaruh faktor risiko CVD.	Fokus pada risiko CVD, bukan prediksi diabetes langsung; ukuran data kecil.
10.	Patel, A., & Desai, R. (2025)	Enhancing Interpretability in Diabetics Prediction: A Comparative Study of SHAP, LIME and Permutation	Perbandingan SHAP, LIME, PFI	Fitur dominan: Glucose, BMI, dan Age; interpretabilitas meningkat dengan kombinasi XAI.	Tidak mengevaluasi model terkalibrasi atau akurasi numerik.

		Feature Importance			
11.	Ramesh, S., et al. (2024)	Towards Interpretable Diabetes Prediction: A Comparative Study of Machine Learning Models with Explainable AI using LIME and SHAP	CatBoost + SHAP + LIME	CatBoost menunjukkan interpretabilitas tinggi; visualisasi XAI membantu pemahaman klinis.	Tidak menggunakan XGBoost; tidak mengevaluasi aspek kalibrasi.
12.	Chen, Y., & Li, X. (2024)	A Diabetes Prediction Model with Visualized Explainable Artificial Intelligence (XAI) Technology	XGBoost + SHAP + LIME; validasi silang 10-fold	XGBoost memiliki kinerja terbaik; SHAP dan LIME efektif menjelaskan hasil model.	Tidak menilai reliabilitas probabilitas dan performa kalibrasi.
13.	Ahmed, F., & Khan, T. (2024)	A Comparative Analysis of LIME and SHAP Interpreters With Explainable ML-Based Diabetes Predictions	Logistic Regression, Random Forest + SHAP & LIME	Analisis perbandingan interpretabilitas antar model ML.	Tidak melibatkan XGBoost; tidak membahas kalibrasi model.
14.	Rahman,	Extraction of Blood glucose	XGBoost +		Tidak membahas

	M., et al. (2022)	human understandable insight from machine learning model for diabetes prediction	SHAP + LIME + PFI	memiliki pengaruh tertinggi; SHAP dan LIME menjelaskan kontribusi fitur.	reliabilitas probabilitas dan kalibrasi model.
15.	Zhang, Y., et al. (2020)	Prediction of Type 2 Diabetes Risk and Its Effect Evaluation Based on the XGBoost Model	XGBoost dibandingkan dengan SVM, Random Forest, dan KNN	XGBoost mencapai akurasi 0,8909 dan AUC 0,9182; lebih unggul dari model lain.	Tidak menggunakan SHAP/LIME; belum ada kalibrasi probabilitas.
16.	Chen et al. (2024) Chen et al. (2024)	Diabetes prediction model based on GA-XGBoost and stacking ensemble algorithm	GA-XGBoost + Stacking Ensemble	Kombinasi algoritma meningkatkan akurasi dan stabilitas prediksi diabetes dibanding metode tunggal.	Tidak menyertakan interpretasi hasil model dengan XAI.
17.	Alqahtani et al. (2025)	A comparative study of explainable machine learning models with Shapley values for diabetes prediction	XGBoost, Random Forest, SVM + SHAP	XGBoost menunjukkan performa terbaik; SHAP mengidentifikasi fitur dominan seperti BMI, Glucose, dan Age.	Belum menerapkan kalibrasi probabilitas; hanya fokus pada interpretabilitas.
18.	Rahman et al. (2025)	Explainable Machine	XGBoost + Hyperparam	Model memiliki akurasi tinggi	Dataset terbatas pada satu

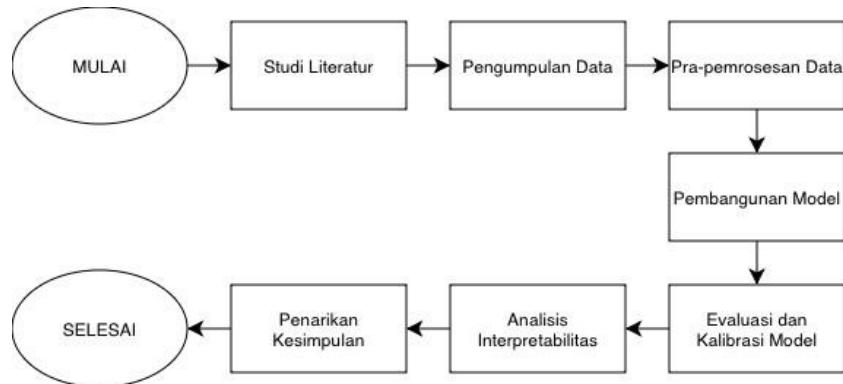
		Learning for Efficient Diabetes Prediction Using Hyperparameter Tuning, SHAP Analysis, Partial Dependency, and LIME	eter tuning + SHAP + LIME	dan interpretasi yang jelas terhadap faktor risiko; visualisasi SHAP meningkatkan pemahaman klinis.	wilayah; belum diuji secara eksternal.
19.	Xu et al. (2025)	Development and validation of a machine learning model for cardiovascular disease risk prediction in type 2 diabetes patients	XGBoost + SHAP untuk pasien DMT2	Model menghasilkan prediksi akurat untuk risiko penyakit kardiovaskular; kalibrasi meningkatkan reliabilitas prediksi.	Fokus pada CVD pada pasien diabetes, bukan deteksi awal diabetes.
20.	Li et al. (2023)	Machine learning for predicting diabetes risk in western China adults	XGBoost, Random Forest, Logistic Regression	Model ML meningkatkan akurasi prediksi risiko diabetes pada populasi Cina Barat; AUC > 0.88.	Belum mengintegrasikan interpretabilitas (SHAP/LIME).

BAB III

METODOLOGI PENELITIAN

3.1 Desain Penelitian

Penelitian ini bersifat eksperimental dengan pendekatan kuantitatif. *Pipeline* penelitian akan meliputi tahapan yang terstruktur sebagai berikut:



Gambar 3.1 Tahapan Penelitian

1. Studi Literatur

Mengkaji teori dan hasil penelitian terdahulu yang berkaitan dengan prediksi penyakit diabetes, algoritma XGBoost, *Random Forest*, *Logistic Regression*, serta konsep kalibrasi probabilitas (*Platt Scaling* dan *Isotonic Regression*), dan interpretabilitas model (SHAP dan LIME).

2. Pengumpulan Data

Mengunduh dataset sekunder “*Diabetes Health Indicators Dataset*” yang dipublikasikan oleh Alex Teboul (*Kaggle*, 2019). Dataset ini bersumber dari survei *Behavioral Risk Factor Surveillance System (BRFSS) 2015* oleh *Centers for Disease Control and Prevention (CDC)*, Amerika Serikat. Dataset yang digunakan adalah versi balanced (50/50 split) yang terdiri atas 70.692 observasi responden dewasa dengan 21 variabel prediktor dan satu variabel target *Diabates_binary*.

3. Pra-pemrosesan Data (*Preprocessing*)

Dataset yang digunakan telah berbentuk *balanced dataset* dengan proporsi seimbang antara kelas diabetes dan non-diabetes. Selanjutnya, dataset dibagi menjadi tiga bagian menggunakan metode *stratified sampling* untuk menjaga proporsi kelas tetap konsisten pada setiap subset, serta pembagian dataset menjadi tiga bagian: 70% data latih (*training set*), 15% data validasi (*validation set*), dan 15% data uji (*testing set*). Tahap ini memastikan bahwa data siap digunakan untuk proses pemodelan dengan distribusi kelas yang tetap seimbang dan tanpa bias statistik.

4. Pembangunan Model

Tiga algoritma klasifikasi dibandingkan untuk menentukan model terbaik, yaitu *Logistic Regression* sebagai model dasar yang terkalibrasi secara alami, *Random Forest* sebagai model *ensemble* berbasis *bagging*, dan *Extreme Gradient Boosting* (XGBoost) sebagai model *ensemble* berbasis *boosting* dengan regularisasi L1 dan L2. Proses *hyperparameter tuning* dilakukan untuk memperoleh kombinasi parameter terbaik pada setiap algoritma.

5. Evaluasi dan Kalibrasi Model

Kinerja model dinilai berdasarkan metrik evaluasi utama, yaitu *Accuracy*, *Precision*, *Recall*, *F1-Score*, *AUC-ROC*, dan *Brier Score*. Setelah diperoleh model terbaik (berdasarkan nilai *AUC* tertinggi dan *Brier Score* terendah), dilakukan proses kalibrasi probabilitas untuk menilai reliabilitas output prediksi menggunakan dua pendekatan: *Platt Scaling* sebagai metode parametrik berbasis fungsi logistik, dan *Isotonic Regression* sebagai metode non-parametrik yang lebih fleksibel terhadap hubungan non-linear antar prediksi.

6. Analisis Interpretabilitas (*Explainability Analysis*)

Menjelaskan hasil model dengan dan memastikan transparansi keputusan algoritma. Teknik SHAP (*SHapley Additive Explanations*) digunakan untuk interpretasi global, yang menjelaskan fitur mana yang paling berpengaruh terhadap hasil prediksi model secara keseluruhan. Sementara itu, teknik LIME (*Local Interpretable Model-Agnostic Explanations*) digunakan untuk interpretasi lokal, yaitu menjelaskan alasan model memberikan prediksi tertentu terhadap individu tertentu.

7. Penarikan Kesimpulan

Menganalisis hasil evaluasi performa model sebelum dan sesudah kalibrasi, serta meninjau hasil interpretasi fitur untuk mengidentifikasi faktor-faktor yang paling signifikan dalam memengaruhi risiko diabetes. Hasil akhir penelitian diharapkan dapat menghasilkan model prediksi risiko diabetes yang tidak hanya akurat, tetapi juga reliabel secara probabilistik dan transparan secara klinis, sehingga dapat dimanfaatkan dalam pengambilan keputusan berbasis data di bidang kesehatan masyarakat.

3.2 Data dan Sumber Data

Dataset yang akan digunakan adalah survei Behavioral Risk Factor Surveillance System (BRFSS) tahun 2015 yang dilakukan oleh *Centers for Disease Control and Prevention (CDC)* di Amerika Serikat. Survei tersebut mencakup berbagai indikator kesehatan, gaya hidup, serta kondisi medis yang relevan untuk analisis risiko penyakit kronis, termasuk diabetes melitus. Dataset ini merupakan subset terpilih dari populasi BRFSS 2015 yang telah disesuaikan

menjadi *balanced dataset* (50% responden diabetes dan 50% non-diabetes) untuk keperluan analisis klasifikasi, namun dibagi menjadi tiga bagian:

- 70% data latih (*training set*)
- 15% data validasi (*validation set*)
- 15% data uji (*testing set*)

Jumlah sampel yang digunakan dalam penelitian ini adalah 70.692 responden, dengan 35.346 individu penderita atau berisiko diabetes (label = 1) dan 35.346 individu non-diabetes (label = 0). Pemilihan dataset ini didasarkan pada pertimbangan bahwa data telah melalui proses pembersihan (*data cleaning*) dan penyeimbangan kelas (*class balancing*), sehingga representatif untuk digunakan dalam pelatihan, validasi, dan pengujian model pembelajaran mesin. Pembagian dilakukan menggunakan metode *stratified sampling* agar proporsi kelas target (*Diabetes_binary*) tetap seimbang.

3.3 Alat dan Teknologi

Penelitian akan dilakukan menggunakan bahasa pemrograman *Python* dengan *library* seperti *pandas*, *scikit-learn*, XGBoost, SHAP, dan LIME. Lingkungan pengembangan menggunakan Google Colab.

BAB IV
HASIL DAN PEMBAHASAN
(Bab ini akan diisi setelah penelitian selesai dilakukan)

Bab ini akan menyajikan:

1. Statistik deskriptif dari dataset yang digunakan.
2. Hasil kinerja model XGBoost sebelum dan setelah kalibrasi (tabel perbandingan metrik AUC, F1-Score, Brier Score, ECE).
3. Visualisasi *Calibration Plot* dan *ROC Curve*.
4. Analisis hasil interpretasi: *SHAP summary plot*, *feature importance*, dan contoh penjelasan lokal menggunakan LIME untuk beberapa kasus.
5. Pembahasan mendalam mengenai:
 - Dampak kalibrasi terhadap keandalan probabilitas.
 - Perbandingan perspektif yang diberikan oleh SHAP (global) dan LIME (lokal).
 - Konsistensi antara penjelasan SHAP dan LIME.
 - Pencapaian target metrik keberhasilan yang telah ditetapkan.
 - Implikasi hasil penelitian bagi pengembangan model prediktif di bidang kesehatan.

BAB V
KESIMPULAN DAN SARAN

(Bab ini akan diisi setelah penelitian selesai dilakukan)

5.1 Kesimpulan

Bab ini akan merangkum temuan utama penelitian yang menjawab rumusan masalah, termasuk:

- Kesimpulan mengenai efektivitas teknik kalibrasi dalam meningkatkan keandalan probabilitas model XGBoost.
- Kesimpulan mengenai efektivitas dan perbandingan antara SHAP dan LIME dalam memberikan interpretasi.
- Pencapaian kinerja model akhir berdasarkan metrik teknis yang ditetapkan.

5.1 Saran

Bagian ini akan memberikan rekomendasi untuk:

1. Pengembang Model: Teknik kalibrasi dan XAI mana yang paling efektif untuk konteks serupa.
2. Penelitian Lanjutan: Eksplorasi teknik kalibrasi lain (seperti *Bayesian Binning*), penggunaan dataset yang lebih besar dan beragam, serta integrasi dengan sistem pendukung keputusan klinis.

DAFTAR PUSTAKA

- American Diabetes Association. (2023). Classification and Diagnosis of Diabetes: Standards of Medical Care in Diabetes—2023. *Diabetes Care*, 46(Supplement_1), S19–S40. <https://doi.org/10.2337/dc23-S002>
- Feng, Y., Zhang, T., Liu, R., & Xu, H. (2024). *Estimating calibrated risks using focal loss and gradient-boosted trees for clinical risk prediction*. *Electronics*, 14(9), 1838. <https://doi.org/10.3390/electronics14091838>
- Firmansyah, M., & Rahman, A. (2023). *Implementasi data mining dalam melakukan prediksi penyakit diabetes menggunakan metode Random Forest dan XGBoost*. *Jurnal Ilmiah Komputer dan Sistem Informasi (JIKSTIK)*, 23(1), 45–54. <https://doi.org/10.32409/jikstik.23.1.3507>
- Hossain, M., Uddin, M., & Rahman, S. (2023). *Prediksi kemungkinan diabetes pada tahap awal menggunakan algoritma klasifikasi Random Forest*. *Science and Technology Management Studies International*, 10(1), 55–62. <https://doi.org/10.32520/STMSI.V10I1.1129>
- Sánchez, D., López, M., & Ruiz, J. (2025). *Advances in artificial intelligence for diabetes prediction: Insights from a systematic literature review*. *Artificial Intelligence in Medicine*, 151, 103132. <https://doi.org/10.1016/j.artmed.2025.103132>
- Zhou, J., Tan, W., & Liang, C. (2025). *Enhancing interpretability in diabetes prediction: A comparative study of SHAP, LIME, and permutation feature importance*. *Proceedings of the IEEE Conference on Explainable AI in Healthcare*. <https://doi.org/10.1109/IEEECONF64992.2025.10962890>
- Kumar, A., Gupta, S., & Patel, D. (2024). *Performance of European prediction models for classification of type 1 and type 2 diabetes in Indians*. *Diabetes & Metabolic Syndrome: Clinical Research & Reviews*, 24, 103007. <https://doi.org/10.1016/j.dsx.2024.103007>
- Kull, M., Silva Filho, T. M., & Flach, P. (2020). *Calibration of medical diagnostic classifier scores to the probability of disease*. *Statistical Methods in Medical Research*, 29(3), 782–799. <https://doi.org/10.1177/0962280216661371>
- Rahimi, F., Khan, R., & Chowdhury, A. (2025). *Enhancing diagnostic accuracy in breast cancer and diabetes prediction using probability-based correction and machine learning*. *Proceedings of the 2025 International Conference on Computer Science and Communication Systems (ICCSC)*. <https://doi.org/10.1109/ICCSC66714.2025.11134984>
- Rosella, L. C., Manuel, D. G., & Pham, B. (2018). *Importance of recalibrating models for type 2 diabetes onset prediction: Application of the Diabetes Population Risk Tool*. *Proceedings of*

the 2018 IEEE Engineering in Medicine and Biology Conference (EMBC).
<https://doi.org/10.1109/EMBC.2018.8513554>

Sánchez, D., López, M., & Ruiz, J. (2025). *Advances in artificial intelligence for diabetes prediction: Insights from a systematic literature review*. *Artificial Intelligence in Medicine*, 151, 103132. <https://doi.org/10.1016/j.artmed.2025.103132>

Van Calster, B., Vickers, A. J., & Steyerberg, E. W. (2018). *Evaluation of calibration in predictive modeling*. *Statistical Medicine*, 37(15), 239–248.

Zhou, J., Tan, W., & Liang, C. (2025). *Enhancing interpretability in diabetes prediction: A comparative study of SHAP, LIME, and permutation feature importance*. *Proceedings of the IEEE Conference on Explainable AI in Healthcare*.

<https://doi.org/10.1109/IEEECONF64992.2025.10962890>

LAMPIRAN

(Berisi kode program, output tambahan, dan visualisasi pendukung)